

Unidad 1

El Lenguaje y la Filosofía de los Datos

Pon a prueba todo lo aprendido en las 4 clases de la Unidad 1.


Actuarás como **Data Analyst Junior** en una empresa real, construyendo un pipeline completo de datos: entorno profesional, álgebra lineal con NumPy, exploración con SQL y transformación con Pandas.

UNIDAD 1

RETO INTEGRADOR

SQL + PYTHON

NIVEL INTERMEDIO



— INTRODUCCIÓN AL RETO

Bienvenido a tu primer reto real como Data Analyst Junior.

Hasta ahora has visto las herramientas por separado — NumPy en una clase, SQL en otra, Pandas en otra. Este reto existe para que entiendas algo fundamental: **en el mundo real nadie te da los datos limpios**, nadie te dice exactamente qué query escribir, y nadie separa el trabajo en cajitas ordenadas.

La empresa es **TechVentas S.A.S.**, una distribuidora de tecnología en Latinoamérica. El CEO acaba de pedir un análisis del primer semestre. El problema: el archivo que dejó el equipo anterior tiene errores — productos en blanco, cantidades negativas y campos vacíos. **Nadie va a limpiar eso por ti.**

No se trata de que todo salga perfecto a la primera. Documenta todo, comenta tu código y explica tus decisiones. **Eso es lo que diferencia a alguien que sabe usar herramientas de alguien que sabe pensar con datos.**

El flujo de un proyecto de datos real

- ▶ **Recibes datos sucios** — CSV con errores intencionales
- ▶ **Los entiendes** — NumPy, estadísticas, álgebra lineal
- ▶ **Los consultas** — SQL, filtros, joins, agrupaciones
- ▶ **Los limpias** — Pandas, `isna()`, filtros, imputación
- ▶ **Extraes valor** — respuestas de negocio para el CEO

*“Tu trabajo es construir el pipeline completo — desde configurar el entorno profesional hasta tener los datos **limpios, estructurados y listos para responder preguntas de negocio**. Ese flujo es exactamente lo que hace un Data Analyst en su primer mes de trabajo.”*

CONTEXTO DEL RETO

TechVentas S.A.S.

Distribuidora de tecnología en Latinoamérica con **6 meses de datos transaccionales**. El CEO necesita respuestas urgentes de negocio, pero el archivo tiene inconsistencias y datos sucios.

Tu misión: actuar como **Data Analyst Junior** y construir un pipeline completo que limpie, estructure y analice la información con las herramientas vistas en clase.



Archivo de datos: **ventas_techventas.csv** — incluido junto a este PDF. No modificar el original.

ESTRUCTURA DEL DATASET

COLUMNA	TIPO	DESCRIPCIÓN
order_id	INTEGER	ID único del pedido
fecha	DATE	Fecha de transacción — parsear al cargar
cliente_id	VARCHAR	Código cliente (C001...C010)
region	VARCHAR	Norte / Sur / Centro / Este / Oeste
producto	VARCHAR	Nombre del producto ⚠ contiene blancos
categoria	VARCHAR	Categoría del producto
cantidad	INTEGER	Unidades ⚠ puede ser negativa
precio_unitario	FLOAT	Precio por unidad en USD
descuento	FLOAT	Porcentaje aplicado (0.00 – 0.20)
vendedor	VARCHAR	Nombre del vendedor responsable

⚠ **Dataset con errores intencionales:** productos en blanco, cantidades negativas y valores nulos — parte del reto es detectarlos y tratarlos correctamente.

Datos del Dataset



60
TRANSACCIONES



10
CLIENTES



6
MESES (ENE–JUN)



4
VENEDORES

🛠 Herramientas que usarás



NumPy
Arrays, álgebra lineal, estadísticas



SQL + SQLite
Consultas, joins, agrupaciones



Pandas
Carga, limpieza, transformación

1

NumPy & Fundamentos Python

Domina las bases matemáticas y el entorno profesional de trabajo

Clases 1 y 2

1.1 Setup del Entorno

Crea un entorno virtual con **Anaconda o venv**. Instala **numpy**, **pandas** y **sqlalchemy**. Documenta cada paso en un archivo **setup.md** en la raíz de tu repositorio GitHub.

```
conda create -n reto_u1 python=3.11
pip install numpy pandas sqlalchemy
```

1.2 Álgebra Lineal Aplicada

En **01_numpy.ipynb**: crea arrays de cantidades y precios del dataset. Calcula el vector de **ingresos brutos** usando multiplicación matricial con **numpy.dot** o el operador **@**. Compara con la multiplicación elemento a elemento.

```
ingresos = np.dot(cantidades, precios)
# o: ingresos = cantidades @ precios
```

1.3 Estadísticas con NumPy

Antes de usar **Pandas**, calcula con NumPy puro sobre el campo **precio_unitario**: media, mediana, desviación estándar y percentiles 25 y 75. Agrega un bloque Markdown explicando qué te dicen estos números sobre el catálogo.

```
np.mean(precios) · np.median(precios)
np.std(precios) · np.percentile(precios, [25, 75])
```

1.4 Reflexión CRISP-DM

En un bloque **Markdown** del notebook, mapea las actividades de este reto a las 6 fases del ciclo **CRISP-DM**. ¿Cuál fase crees que es la más importante aquí y por qué? **Mínimo 5 líneas de reflexión personal**.



¿Qué debes entregar de la Parte 1?

Notebook **01_numpy.ipynb** con las 4 tareas resueltas y comentadas. Archivo **setup.md** con instrucciones de instalación paso a paso. Todos los resultados deben mostrarse al ejecutar *Kernel* → *Restart & Run All*.

2

SQL para Exploración de Datos (Data Discovery)

Consulta, filtra, agrupa y relaciona datos directamente desde la base de datos

Clase 3

Importa **ventas_techventas.csv** en SQLite usando **pandas.to_sql()** + **sqlalchemy**. Escribe y guarda cada query en **02_sql_discovery.sql**. Ejecútalas también desde el notebook con **pd.read_sql()** para ver los resultados.

Q1 SELECT DISTINCT

Lista todos los **productos únicos** disponibles usando un alias de columna descriptivo.

Q2 WHERE + BETWEEN

Filtra pedidos del **primer trimestre** (ene-mar 2024) con cantidad mayor a 5 unidades.

Q3 GROUP BY + HAVING

Vendedores cuyo **ingreso bruto total** (cantidad × precio) supera **\$10,000 USD**.

Q4 COUNT + SUM + AVG

Por **categoría**: total de pedidos, suma de unidades vendidas y precio unitario promedio.

Q5 JOIN

Crea la tabla **vendedores** (abajo) y calcula el **% de cumplimiento** de meta de cada uno.

Q6 Subconsulta

Encuentra el **cliente que generó el mayor ingreso total** en el primer semestre.

Tabla vendedores — créala para la Q5

vendedor	zona	meta_mensual (\$)
Ana López	Norte	8,000
Carlos Ruiz	Sur	7,500
Luis Mora	Norte	8,000
Maria Torres	Centro	7,000



¿Qué debes entregar de la Parte 2?

Archivo **02_sql_discovery.sql** con las 6 queries comentadas.

Notebook **02_sql_discovery.ipynb** mostrando los resultados de cada query ejecutada con **pd.read_sql()**.

La tabla **vendedores** debe estar creada en la base de datos SQLite.

3

Ingeniería de Datos con Pandas

Carga, limpia, transforma y exporta el dataset completo

Clase 4

```
import pandas as pd
import numpy as np
from sqlalchemy import create_engine

# 3.1 · Carga con parseo de fechas y encoding
df = pd.read_csv('ventas_techventas.csv', parse_dates=['fecha'], encoding='utf-8')

# 3.2 · Limpieza - detectar y tratar errores
df = df[df['producto'].notna() & (df['producto'] != '')]
df = df[df['cantidad'] > 0]

# 3.3 · Feature Engineering
df['ingreso_bruto'] = df['cantidad'] * df['precio_unitario']
df['ingreso_netto'] = df['ingreso_bruto'] * (1 - df['descuento'])
df['mes'] = df['fecha'].dt.to_period('M')

# 3.4 · Agrupación mensual
resumen = df.groupby('mes').agg(total=('ingreso_netto', 'sum'), n=('order_id', 'count'))

# 3.5 · Exportar a SQLite y verificar
engine = create_engine('sqlite:///techventas.db')
df.to_sql('ventas', engine, if_exists='replace', index=False)
```

3.1 Carga el CSV con **read_csv** — especifica encoding y parse_dates. Muestra **df.info()** comentado con tus observaciones.

3.2 Detecta nulos con **isna()**. Elimina/imputa justificando tu estrategia. Documenta cuántos registros se descartaron y por qué.

3.3 Crea columnas **ingreso_bruto**, **ingreso_netto** y **mes**. Agrupa por mes con **groupby** + **agg**.

3.4 Usa **concat** o **merge** para unir el resumen mensual con una tabla de metas. Calcula el % de cumplimiento.

3.5 Exporta con **to_sql** y verifica leyendo de vuelta con **read_sql('SELECT COUNT(*) FROM ventas', engine)**.

Estructura del Repositorio GitHub

```
reto_unidad1_<tu_nombre>/ |— README.md descripción + cómo ejecutar |—
setup.md pasos de configuración |— data/ |— ventas_techventas.csv |—
notebooks/ |— 01_numpy.ipynb |— 02_sql_discovery.ipynb |—
03_pandas_pipeline.ipynb |— sql/ |— 02_sql_discovery.sql |— output/ |
techventas.db (SQLite generado) |— requirements.txt
```

Instrucciones de Entrega

- 1 Sube a un repositorio público en GitHub con nombre **reto_unidad1_<tu_nombre>**
- 2 **README.md** con descripción del proyecto e instrucciones de ejecución claras
- 3 Todos los notebooks deben correr con **Kernel → Restart & Run All** sin errores
- 4 Pega el link en el campo de entrega de la **plataforma Dev Senior Code**
- 5 Fecha límite: revisa el calendario de tu cohorte en la plataforma

CRITERIOS DE EVALUACIÓN

✓ Rúbrica de Evaluación

100
puntos totales

CRITERIO	INDICADORES DE LOGRO	PUNTOS
Entorno y Setup Clases 1–2	Entorno virtual funcional · requirements.txt con versiones · setup.md con pasos claros y reproducibles	15 15%
NumPy & Álgebra Clase 2	Arrays de cantidades/precios correctos · multiplicación matricial con numpy.dot · estadísticas descriptivas (media, mediana, std, percentiles 25/75)	25 25%
SQL Discovery Clase 3	6 queries ejecutando sin errores · uso correcto de SELECT DISTINCT, WHERE, BETWEEN, GROUP BY, HAVING, JOIN y subconsulta · comentadas en el archivo <code>.sql</code>	25 25%
Pipeline Pandas Clase 4	Limpieza documentada (isna , filtros) · columnas ingreso_bruto, ingreso_netto, mes creadas · groupby + agg correcto · exportación SQLite verificada con <code>read_sql</code>	25 25%
Calidad del Repo General	README con descripción e instrucciones · estructura de carpetas correcta · notebooks corren con Restart & Run All sin errores	10 10%
TOTAL		100



Mensaje del Instructor

No te preocupes por la perfección — el objetivo es practicar el flujo completo: **datos** → **limpieza** → **SQL** → **Python** → **insight**. Si algo no funciona, documenta qué intentaste y por qué no funcionó. El proceso de aprendizaje también cuenta. ¡Mucho éxito!